

Formation d'ingénieur généraliste 2A
Parcours de S8 : *Sciences de l'Information et Société Numérique*

Rapport de stage

Modélisation de la consommation des conteneurs réfrigérés (reefers)

Élève :

Aya Bouchama

Maîtres de stage :

M. Guillaume Graton

Mme Marwa Boulakebch

Tuteurs école :

Mme Muriel Roche

Mme Caroline Fossati

Période de stage : du 01/06/2026 au 31/07/2026

Année universitaire 2025 – 2026

Remerciements

Je remercie tout d'abord Monsieur Guillaume Graton, qui m'a donné l'opportunité de faire ce stage dans un laboratoire de recherche et pour m'avoir permis de choisir, parmi plusieurs sujets proposés, celui qui m'intéressait le plus, une liberté que j'ai particulièrement appréciée. Je le remercie aussi pour son accompagnement tout au long du stage, sa disponibilité pour discuter du projet, et sa réactivité quand j'avais besoin de faire mes démarches administratives. Sa présence constante auprès de l'ensemble des stagiaires, son attention et ses retours toujours constructifs ont largement contribué à la qualité de ce stage.

Je souhaite également exprimer ma sincère gratitude à ma tutrice, Madame Marwa Boulakebch, postdoctorante, qui m'a accompagnée quotidiennement tout au long de ce stage. Elle venait voir tous les jours où j'en étais et si j'avais des difficultés, et j'ai toujours pu me tourner vers elle en cas de besoin. Même pendant la semaine où j'ai travaillé à distance, elle est restée présente, avec des réunions régulières pour continuer à avancer ensemble. Sa bienveillance, ses conseils et sa présence tout au long du stage ont grandement facilité mon intégration et ma progression.

Je remercie enfin l'ensemble de l'équipe pour l'accueil chaleureux qui m'a été réservé durant ces deux mois de stage.

Résumé

Ce stage de deuxième année, réalisé au sein du Laboratoire d'Informatique et des Systèmes (LIS), s'inscrit dans le projet TNTM, un partenariat de recherche entre CMA CGM et le LIS visant à exploiter les données numériques collectées à bord des navires porte-conteneurs. Le travail porte spécifiquement sur les conteneurs réfrigérés (reefers), dont la consommation électrique, difficile à anticiper, représente un enjeu énergétique, économique et environnemental pour l'armateur.

L'objectif est de comparer deux approches de modélisation de la consommation électrique des reefers sur un voyage de référence (Leg 30, Singapour-Valence) : une approche par série temporelle, ARIMAX, exploitant la dépendance temporelle de la consommation et la température ambiante comme variable exogène ; et une approche par apprentissage automatique, XGBoost, permettant d'intégrer des variables contextuelles supplémentaires (consigne de température, âge des équipements) et d'exploiter un entraînement poolé sur plusieurs sources et plusieurs legs.

Un protocole rigoureux d'entraînement, de validation et de test est mis en place pour garantir une évaluation non biaisée des deux modèles. Les résultats montrent qu'ARIMAX, bien qu'interprétable, souffre d'une dérive en prédiction one-shot que sa version à réactualisation corrige partiellement, avec une performance étroitement liée à la volatilité de chaque source. XGBoost, à mémoire équivalente, surpasse ARIMAX d'environ 30 % sur le RMSE relatif moyen (11,4 % contre 16,3 %), et atteint 7,8–7,9 % une fois enrichi de variables contextuelles et entraîné sur un périmètre poolé de 7 legs, confirmant l'intérêt de l'apprentissage automatique pour cette tâche de prédiction.

Mots-clés : consommation énergétique, conteneurs réfrigérés, prédiction de série temporelle, ARIMAX, XGBoost, apprentissage automatique, transport maritime.

Abstract

This second-year internship, carried out at the Laboratoire d'Informatique et des Systèmes (LIS), is part of the TNTM project, a research partnership between CMA CGM and LIS aimed at leveraging the digital data collected on board container ships. The work focuses specifically on refrigerated containers (reefers), whose electrical consumption is difficult to anticipate and represents an energy, economic and environmental challenge for the shipowner.

The objective is to compare two modeling approaches for reefer electrical consumption on a reference voyage (Leg 30, Singapore-Valencia) : a time-series approach, ARIMAX, exploiting the temporal dependency of consumption together with ambient temperature as an exogenous variable ; and a machine learning approach, XGBoost, allowing the integration of additional contextual variables (temperature setpoint, equipment age) and pooled training across multiple sources and multiple legs.

A rigorous train/validation/test protocol is set up to ensure an unbiased evaluation of both models. Results show that ARIMAX, although interpretable, suffers from drift in one-shot prediction, partially corrected by its rolling-update version, with performance closely tied to each source's volatility. At equivalent memory, XGBoost outperforms ARIMAX by about 30 % on the average relative RMSE (11.4 % vs 16.3 %), and reaches 7.8–7.9 % once enriched with contextual features and trained on a pooled perimeter of 7 legs, confirming the value of machine learning for this prediction task.

Keywords : energy consumption, refrigerated containers, time series forecasting, ARIMAX, XGBoost, machine learning, maritime transport.

Utilisation de l'intelligence artificielle pour la rédaction de ce rapport

Pour la rédaction de ce rapport, j'ai utilisé l'intelligence artificielle pour la correction orthographique et grammaticale de mes phrases, ainsi que pour m'aider à reformuler et structurer clairement mes idées. Le contenu, les idées, les analyses et les résultats présentés restent entièrement les miens.

Table des matières

Introduction	6
1 Présentation du laboratoire d'accueil	7
1.1 Le Laboratoire d'Informatique et des Systèmes (LIS)	7
1.2 Organisation	7
1.3 Présentation de la mission	8
1.3.1 Objectifs de la mission qui m'a été confiée	8
2 Contenu scientifique et professionnel	10
2.1 Données et protocole expérimental	10
2.1.1 Le navire et son voyage	10
2.1.2 Le reefer : un conteneur sous surveillance thermique constante	10
2.1.3 Mesure de la consommation : les points d'alimentation	10
2.1.4 Position physique des sources à bord	10
2.1.5 Consommation électrique : la donnée cible	11
2.1.6 Facteurs contextuels influençant la consommation	11
2.1.7 Construction du jeu de données final	11
2.1.8 Présentation détaillée du Leg 30	11
2.1.9 Protocole d'entraînement, de validation et de test	12
2.1.10 Critère d'évaluation	12
2.2 Étude de l'existant et positionnement méthodologique	13
2.3 Modélisation par série temporelle : ARIMAX	14
2.3.1 Pourquoi ARIMAX ?	14
2.3.2 Définition du modèle	14
2.3.3 Implémentation initiale du modèle : prédiction en une seule fois (V0)	15
2.3.4 Résultats et analyse	16
2.3.5 Étude de l'impact de l'horizon de prédiction (approche multi-horizons)	18
2.3.6 Mise à jour rolling (V2) : principe et analyse du mécanisme	21
2.3.7 Synthèse et limites du modèle ARIMAX	23
2.4 Modélisation par apprentissage automatique : XGBoost	24
2.4.1 Définition du modèle	24
2.4.2 Sélection des hyperparamètres	25
2.4.3 Comparaison ARIMAX vs XGBoost – Système dynamique autorégressif	25
2.4.4 Enrichissement du modèle XGBoost par des features contextuelles	27
2.4.5 Bilan de l'enrichissement	32
2.5 Synthèse comparative et valeur ajoutée	32
2.6 État final et perspectives	33
3 Les compétences centraliennes et l'utilisation de l'intelligence artificielle	34
3.1 Les compétences centraliennes	34
3.2 L'utilisation de l'intelligence artificielle dans le cadre de ce stage	36
Conclusion	37
Bibliographie	38

Introduction

Le transport maritime conteneurisé, colonne vertébrale du commerce international, fait face à des exigences croissantes de sobriété énergétique, dans un contexte réglementaire visant la neutralité carbone du secteur à l’horizon 2050. Parmi les postes de consommation électrique embarqués, les conteneurs réfrigérés, ou reefers, occupent une place particulière : leur unité de réfrigération fonctionne en continu pour maintenir une température de consigne, sur des traversées pouvant durer plusieurs semaines, ce qui en fait l’un des postes de consommation les plus importants et les plus variables à bord d’un porte-conteneurs.

C’est dans ce cadre que s’inscrit le projet TNTM (Transformation Numérique du Transport Maritime), partenariat de recherche entre l’armateur CMA CGM et le Laboratoire d’Informatique et des Systèmes (LIS), qui vise à exploiter les données numériques collectées à bord des navires pour optimiser la gestion opérationnelle et réduire l’impact environnemental du transport maritime. Ce stage s’est positionné sur le sous-lot du projet consacré à l’analyse des données des reefers, avec pour objectif de proposer et de comparer différentes approches de modélisation permettant de prédire leur consommation électrique.

Deux approches méthodologiques ont été explorées. La première s’appuie sur ARIMAX, un modèle statistique de série temporelle exploitant la dépendance de la consommation à ses propres valeurs passées ainsi qu’à la température ambiante, afin d’établir une référence de performance interprétable. La seconde s’appuie sur XGBoost, un modèle d’apprentissage automatique capable de capturer des relations non linéaires et d’intégrer des variables contextuelles supplémentaires (consigne de température, âge des équipements), avec un entraînement poolé sur plusieurs sources et plusieurs voyages.

Ce rapport présente, dans un premier temps, le laboratoire d’accueil et le cadre de la mission confiée. Il détaille ensuite le contenu scientifique du travail réalisé : le protocole expérimental mis en place, la modélisation par ARIMAX et ses limites, puis la modélisation par XGBoost et son enrichissement progressif, avant de proposer une synthèse comparative des deux approches. Il revient enfin sur les compétences développées au cours de ce stage.

1 Présentation du laboratoire d'accueil

1.1 Le Laboratoire d'Informatique et des Systèmes (LIS)

Mon stage s'est déroulé au sein du Laboratoire d'Informatique et des Systèmes (LIS), une unité mixte de recherche (UMR 7020) placée sous la tutelle du CNRS, d'Aix-Marseille Université et de l'Université de Toulon, avec Centrale Méditerranée comme établissement partenaire.

Le LIS a été créé en 2018, à la suite de la fusion de deux laboratoires historiques de la région : le Laboratoire d'Informatique Fondamentale de Marseille (LIF), centré sur les fondements théoriques de l'informatique et le calcul, et le Laboratoire des Sciences de l'Information et des Systèmes (LSIS), qui regroupait notamment des activités en sciences des données, en calcul et en systèmes d'information. Cette fusion a permis de rassembler au sein d'une même structure des compétences complémentaires en informatique, en automatique, en traitement du signal et de l'image, ainsi qu'en science des données.

Le laboratoire compte aujourd'hui plusieurs centaines de membres, parmi lesquels des enseignants-chercheurs et chercheurs titulaires, des post-doctorants, des doctorants ainsi que du personnel ingénieur et technique. Ses locaux sont répartis sur plusieurs campus de la région (Saint-Jérôme, Luminy et Château-Gombert à Marseille, ainsi que La Garde à Toulon), reflétant la diversité de ses tutelles et de ses partenariats académiques.

1.2 Organisation

Le LIS est structuré autour d'une direction, de quatre pôles scientifiques et, au sein de chaque pôle, de plusieurs équipes de recherche, pour un total d'une vingtaine d'équipes :

- **Pôle Analyse et Contrôle des Systèmes (ACS)** : automatique, diagnostic et commande des systèmes ;
- **Pôle Calcul** : algorithmique, complexité et fondements du calcul ;
- **Pôle Sciences des Données (SD)** : représentation, gestion et exploitation des données, intelligence artificielle et apprentissage automatique ;
- **Pôle Signal et Image (SI)** : traitement du signal, de l'image et de la vidéo.

Chaque pôle est piloté par un ou plusieurs responsables de pôle, qui coordonnent les activités scientifiques des équipes qui le composent. Au sein de chaque équipe se côtoient différents profils : maîtres de conférences, professeurs des universités, chercheurs post-doctorants, doctorants, ainsi que des ingénieurs de recherche.

J'ai été accueillie au sein de l'équipe **IACD (Intelligence Artificielle Centrée Données)**, rattachée au pôle Sciences des Données, sous la responsabilité de ma tutrice Madame Marwa Boulakebch. Cette équipe travaille sur le développement de méthodes et d'outils permettant de maximiser la valeur des données disponibles pour l'IA, à travers des thématiques telles que le prétraitement et la transformation de données, la fouille de données ou encore les pipelines de science des données appliqués à des domaines variés (médecine, environnement, transport). Mon encadrant, Monsieur Guillaume Gratton, est quant à lui membre de l'équipe **DIAPRO**, rattachée au pôle Analyse et Contrôle des Systèmes, dont les travaux portent sur le diagnostic, le pronostic et la tolérance aux défauts des systèmes dynamiques.

1.3 Présentation de la mission

Le stage s’inscrit dans le cadre du projet TNTM (Transformation Numérique du Transport Maritime), un partenariat de recherche établi sur quatre ans entre l’armateur CMA CGM et le laboratoire LIS. Ce projet vise à moderniser la gestion du transport maritime en exploitant les données numériques collectées à bord des navires, dans une double perspective d’optimisation opérationnelle et de réduction de l’impact environnemental, en cohérence avec les objectifs de neutralité carbone fixés par le secteur maritime à l’horizon 2050.

Le projet est organisé en plusieurs lots. Le Lot 4 porte spécifiquement sur l’étude des données électriques des réseaux 6600V et 440V à bord de navires porte-conteneurs de 15 000 EVP (équivalent vingt pieds), et se décompose en trois sous-lots :

- Sous-lot 4.1 : installation du système de collecte de données à bord (capteurs, réseau de remontée, stockage) ;
- Sous-lot 4.2 : analyse des données relatives aux conteneurs frigorifiques (reefers) ;
- Sous-lot 4.3 : analyse des données des autres consommateurs électriques du bord.

Le stage se positionne sur le sous-lot 4.2. Les reefers constituent en effet l’un des postes de consommation électrique les plus importants à bord d’un porte-conteneurs, leur fonctionnement continu de réfrigération étant directement soumis à des facteurs très variables (température de consigne, conditions climatiques rencontrées, position à bord, caractéristiques propres à chaque unité). Cette consommation reste aujourd’hui difficile à anticiper avec précision, ce qui limite la capacité de CMA CGM à optimiser la gestion énergétique de sa flotte.

Disposer d’un modèle fiable de prédiction de cette consommation représente ainsi un enjeu à plusieurs niveaux pour l’entreprise : un enjeu énergétique, en permettant une meilleure anticipation des besoins électriques et une gestion plus fine des ressources à bord ; un enjeu économique, à travers une réduction potentielle des coûts d’exploitation liés à la surconsommation ou au surdimensionnement des capacités électriques ; et un enjeu environnemental, en contribuant à la réduction de l’empreinte carbone du transport maritime, dans un contexte réglementaire international de plus en plus exigeant sur ce point.

1.3.1 Objectifs de la mission qui m’a été confiée

À mon arrivée, l’objectif fixé par le laboratoire, en concertation avec les attentes de CMA CGM, était de proposer et de comparer différentes approches de modélisation permettant de prédire la consommation électrique des reefers, en s’appuyant sur les données réelles d’un voyage (leg) de navire mises à disposition par ma tutrice.

Le périmètre de travail initial a été délimité au Leg 30 (trajet Singapour–Valence du CMA CGM Grace Bay), ce choix ayant été fait par ma tutrice sur le critère de la complétude des données disponibles pour ce trajet par rapport aux autres legs.

La mission s’est articulée en deux temps, correspondant à deux approches méthodologiques distinctes et complémentaires :

1. Une première approche par série temporelle (ARIMAX), visant à exploiter la structure temporelle intrinsèque de la consommation ainsi que l’effet de la température ambiante comme variable exogène, avec pour objectif d’établir une référence de performance et d’étudier sa robustesse selon différents horizons de prédiction ;
2. Une seconde approche par apprentissage automatique (XGBoost), visant d’abord à être comparée à ARIMAX à mémoire équivalente, puis à enrichir la modélisation

à l'aide de variables contextuelles supplémentaires (consigne de température, âge des reefers), afin de capturer des relations plus complexes que celles accessibles à un modèle linéaire.

2 Contenu scientifique et professionnel

2.1 Données et protocole expérimental

2.1.1 Le navire et son voyage

Le CMA CGM Grace Bay est un porte-conteneurs assurant des rotations régulières entre l’Asie et l’Europe. Chaque trajet reliant deux ports consécutifs constitue un *leg* : le fichier des legs recense ainsi l’ensemble des voyages effectués par le navire, chacun identifié par un numéro et associé à ses dates et ports de départ et d’arrivée. Le travail présenté ici se concentre sur le **Leg 30**, reliant Singapour à Valence, retenu pour la complétude de ses données par rapport aux autres voyages disponibles.

2.1.2 Le reefer : un conteneur sous surveillance thermique constante

Parmi les conteneurs chargés à bord, certains sont réfrigérés ; ce sont les *reefers*. Ils maintiennent une température de consigne (*setpoint*) permettant de conserver des marchandises périssables, qu’il s’agisse de produits surgelés à des températures très négatives ou de fruits frais à quelques degrés au-dessus de zéro. Ils existent en deux tailles, 20 et 40 pieds, les seconds étant majoritaires dans le parc du navire.

Le maintien de cette température de consigne repose sur une unité de réfrigération embarquée qui doit continuellement compenser les apports de chaleur provenant de l’environnement extérieur. Cette consommation électrique n’est donc pas constante : elle varie en fonction de plusieurs facteurs propres à chaque reefer et à son environnement immédiat, qui seront détaillés plus loin.

2.1.3 Mesure de la consommation : les points d’alimentation

Les reefers ne sont pas mesurés individuellement à bord ; cela nécessiterait un capteur par conteneur. La consommation est à la place mesurée au niveau de points d’alimentation collectifs, appelés *sources* (ou *Reefer Panels*, RP), chacun alimentant électriquement un groupe de reefers situés dans une même zone du navire. La grandeur mesurée à chaque source est donc un **signal agrégé** : la somme des puissances appelées par l’ensemble des reefers connectés à ce point, et non la consommation d’une unité isolée.

Le nom de chaque source encode directement sa localisation physique à bord , par exemple, une source peut regrouper les reefers de deux tranches transversales voisines du navire, situées sur le pont et sur un bord donné. C’est cette information de position qui permettra ensuite de relier chaque mesure de consommation à un contexte physique précis.

2.1.4 Position physique des sources à bord

La position de chaque source est décrite par trois coordonnées standardisées :

- le **Bay**, qui identifie la tranche transversale du navire selon l’axe avant-arrière ;
- le **Tier**, qui distingue les positions en cale (*CH*), protégées, des positions sur le pont (*DECK*), directement exposées au rayonnement solaire et aux conditions climatiques ;
- le **Row**, qui indique le côté bâbord (*PS*) ou tribord (*STD*) du navire.

Cette information de position n’est pas anecdotique : les reefers situés sur le pont sont soumis à des apports thermiques bien plus importants que ceux placés en cale, ce qui se

traduit directement par des niveaux de consommation différents pour un même setpoint et une même température ambiante.

2.1.5 Consommation électrique : la donnée cible

La consommation électrique de chaque source est enregistrée à haute fréquence (minute par minute), puis rééchantillonnée à un pas de temps de 2 heures pour l'ensemble des analyses, afin de s'aligner avec la fréquence disponible pour la température ambiante. Cette valeur, exprimée en kilowatts, constitue la variable cible que l'ensemble des modèles présentés dans ce chapitre cherchent à prédire. Elle fluctue en permanence, reflétant le fonctionnement intermittent des compresseurs des différents reefers connectés à une même source, chacun s'activant et s'arrêtant selon ses propres besoins thermiques.

2.1.6 Facteurs contextuels influençant la consommation

La consommation mesurée à chaque source dépend simultanément de plusieurs catégories de facteurs, environnementaux et opérationnels.

Facteurs environnementaux. La **température ambiante**, mesurée à 2 mètres au-dessus du niveau de la mer, constitue le facteur environnemental le plus déterminant : plus la température extérieure est élevée, plus les reefers doivent fournir d'effort pour maintenir leur consigne, généralement bien inférieure à cette température ambiante. La **vitesse du vent relatif** intervient également, dans une moindre mesure : un vent relatif soutenu améliore le refroidissement naturel des conteneurs situés en pont, ce qui tend à réduire légèrement leur consommation.

Facteurs opérationnels. Pour chaque reefer chargé pendant le leg étudié, plusieurs caractéristiques sont connues : sa **consigne de température** (setpoint), qui détermine directement l'écart à combler avec la température ambiante et donc l'intensité de l'effort de réfrigération ; son **poids brut**, un conteneur plus lourd présentant une masse thermique plus importante ; et l'**âge de son équipement**, un matériel plus ancien étant généralement moins efficace énergétiquement. Ces caractéristiques, connues au niveau de chaque reefer individuel, sont ensuite agrégées au niveau de chaque source pour construire les variables contextuelles utilisées par les modèles.

2.1.7 Construction du jeu de données final

Le jeu de données final exploité dans ce travail résulte de la fusion de ces différentes sources d'information : la série temporelle de consommation par source, la température ambiante sur la même période, ainsi que les caractéristiques contextuelles des reefers connectés à chaque source, reliées à cette dernière via sa position physique (Bay/Tier/Row). Cette chaîne de préparation des données a été fournie en amont par la tutrice et n'a pas été développée dans le cadre de ce travail ; seuls son utilisation et le jeu de données final qui en résulte relèvent de la présente étude.

2.1.8 Présentation détaillée du Leg 30

Le travail s'appuie sur les données du **Leg 30**, trajet du navire CMA CGM Grace Bay reliant Singapour à Valence du 11 janvier au 4 février 2025. Ce leg a été retenu

comme périmètre principal de travail sur recommandation de la tutrice, en raison de la complétude de ses données par rapport aux autres voyages disponibles.

Il regroupe 12 sources d'alimentation électrique, chacune desservant plusieurs reefers connectés simultanément, pour un total de 159 reefers. Les mesures de consommation, la température ambiante et l'ensemble des variables contextuelles associées sont rééchantillonnées à une fréquence de 2 heures, sur une durée totale de 24,66 jours (591,9 heures).

Pourquoi 12 sources sur ce leg. Le nombre de sources d'alimentation électrique retenues pour le Leg 30 résulte de deux filtres appliqués successivement lors de la constitution du jeu de données.

Le premier filtre porte sur la position physique des reefers à bord. Seules les positions situées sur le pont (*DECK*), et regroupant au moins trois reefers simultanément connectés, sont conservées ; les positions en cale (*CH*) ainsi que les positions isolées, desservant un nombre de reefers jugé trop faible pour une modélisation fiable, sont écartées.

Le second filtre porte sur l'activité réelle de chaque source au cours du leg. Une source est considérée comme inutilisée, et par conséquent exclue, si sa consommation mesurée reste inférieure à 1 kW pendant au moins 95 % de la durée du leg, ce qui traduit une source techniquement présente mais non exploitée pendant le trajet .

L'application successive de ces deux filtres au Leg 30 aboutit aux 12 sources d'alimentation électrique retenues pour ce travail, desservant un total de 159 reefers.

2.1.9 Protocole d'entraînement, de validation et de test

L'ensemble des expérimentations repose sur un découpage chronologique des données en trois parties : 80 % pour l'apprentissage, 10 % pour la validation et 10 % pour le test. Ce choix résulte d'une évolution du protocole initial, qui reposait sur une simple séparation 90 %/10 % entre apprentissage et test. Le passage à un découpage à trois parties permet de disposer d'un ensemble de validation indépendant pour la sélection des hyperparamètres : l'ordre (p, q) pour ARIMAX et la fenêtre temporelle ainsi que les hyperparamètres pour XGBoost , sans jamais exposer le jeu de test à ce choix, ce qui évite un biais optimiste dans l'évaluation finale des modèles.

Sur le Leg 30, ce découpage se traduit par 37 774 observations d'apprentissage, 4 722 observations de validation et 4 727 observations de test, contre 42 496 observations d'apprentissage et 4 727 observations de test dans l'ancien protocole 90/10.

2.1.10 Critère d'évaluation

Le critère retenu pour évaluer et comparer les résultats est le **RMSE**, car il pénalise davantage les grandes erreurs grâce au terme au carré, et s'exprime dans la même unité que la consommation (kW), ce qui permet une interprétation directe des résultats. Le modèle retenu, à chaque comparaison, est celui qui minimise le RMSE sur le jeu de test.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (1)$$

où n représente le nombre total de points de prédiction sur la période de test.

Le RMSE brut ne permet toutefois pas à lui seul de comparer les sources entre elles, car son ordre de grandeur dépend directement de leur échelle de consommation, qui varie ici d'un facteur supérieur à 14 selon les sources. Une même erreur absolue représente ainsi

un écart très différent selon que la source consomme quelques kW ou plusieurs dizaines de kW. Pour permettre une comparaison équitable entre sources, le **RMSE relatif** est également utilisé, en rapportant le RMSE à la consommation moyenne réelle sur la période de test :

$$\text{RMSE relatif} = \frac{\text{RMSE}}{\bar{y}_{\text{test}}} \quad (2)$$

où $\bar{y}_{\text{test}}$ désigne la consommation moyenne réelle sur le jeu de test. Ce critère, exprimé en pourcentage, corrige le biais d'échelle et est utilisé dans l'ensemble des analyses comparatives présentées dans ce chapitre.

2.2 Étude de l'existant et positionnement méthodologique

Avant d'engager la modélisation, une étude de l'existant a été menée, en s'appuyant notamment sur deux travaux de recherche déjà réalisés par l'équipe du projet TNTM sur ce même problème de prédiction de la consommation des reefers [4, 5], afin de situer les approches retenues dans ce stage par rapport à la littérature.

Approches statistiques classiques. Les premiers travaux de prévision de consommation énergétique reposent sur des modèles statistiques de série temporelle tels qu'ARIMA et ses extensions à variables exogènes, ARIMAX et SARIMAX. Ces modèles restent largement utilisés pour leur simplicité, leur interprétabilité et leur efficacité sur des historiques de données limités, mais présentent une limite structurelle pour capturer des dépendances non linéaires ou des dynamiques temporelles complexes [4].

Approches par apprentissage automatique. Pour dépasser ces limites, des modèles d'apprentissage automatique tels que Random Forest et XGBoost ont été appliqués à la prévision de consommation énergétique, y compris dans le domaine maritime. XGBoost est en particulier reconnu pour son faible coût de calcul et sa bonne interprétabilité relative, mais son usage combiné à des variables exogènes contextuelles reste peu exploré dans la littérature [4].

Approches par apprentissage profond et physique-guidé. Des architectures de deep learning (LSTM, TimeXer) ainsi que des approches hybrides combinant modèle physique et apprentissage automatique (*physics-informed machine learning*) ont également été proposées pour la prévision de consommation énergétique avec variables exogènes [5]. Ces approches améliorent la performance en intégrant explicitement le contexte, mais restent centrées sur le modèle, avec une interprétabilité limitée, et nécessitent des volumes de données importants pour converger, ce qui les rend peu adaptées au volume disponible dans ce stage (une quarantaine de voyages).

Constat et positionnement. À la connaissance des auteurs de [4], aucune étude ne traite spécifiquement le cas de la consommation embarquée des reefers, où les conditions opérationnelles et environnementales varient dynamiquement d'un voyage à l'autre. C'est ce constat qui motive la démarche méthodologique suivie dans ce stage : partir d'un modèle statistique classique et interprétable, ARIMAX, exploitant la dépendance temporelle et la température ambiante comme variable exogène, afin d'établir une référence de performance robuste malgré le volume de données limité ; puis évoluer vers un modèle

d'apprentissage automatique, XGBoost, capable de capturer des relations non linéaires et d'intégrer des variables contextuelles supplémentaires (consigne de température, âge des équipements), sans nécessiter le volume de données qu'exigeraient des architectures de deep learning ou physique-guidées. Cette progression, de l'interprétable vers le non linéaire, est cohérente avec l'état de l'art identifié et avec les contraintes de données propres à ce projet.

2.3 Modélisation par série temporelle : ARIMAX

2.3.1 Pourquoi ARIMAX ?

La consommation électrique mesurée à chaque source est une grandeur temporelle : elle évolue continûment dans le temps et présente une dépendance à ses propres valeurs passées. Mais elle ne s'explique pas uniquement par sa propre dynamique interne ; parmi les variables explicatives disponibles, une analyse de corrélation a révélé un lien quasi linéaire très marqué entre la consommation et la température ambiante, avec un coefficient de corrélation d'environ 0,99. Ce constat désigne naturellement la température ambiante comme variable exogène pertinente pour la prédiction.

Le problème posé combine donc deux dimensions : une dépendance temporelle intrinsèque (ce que valait la consommation aux instants précédents) et une dépendance à une variable externe mesurée en parallèle (la température ambiante). ARIMAX répond directement à cette double structure, en associant une composante autorégressive et moyenne mobile (AR/MA), qui capture la mémoire propre de la série, à une composante exogène (X), qui intègre l'effet de la température.

Ce choix est également guidé par le volume de données disponible. L'étude porte sur une quarantaine de voyages au total, un volume jugé insuffisant pour envisager des approches de deep learning, réputées gourmandes en données pour converger vers des résultats fiables. ARIMAX, à l'inverse, est un modèle statistique classique, peu paramétré et interprétable, exploitable même avec un historique limité comme celui du Leg 30. Il constitue ainsi un point de départ méthodologique cohérent, avant d'être confronté dans la suite de ce chapitre à ses propres limites.

2.3.2 Définition du modèle

Le modèle utilisé s'écrit sous la forme suivante [1] :

$$\hat{y}(t) = c + \sum_{i=1}^p \phi_i \cdot y(t-i) + \sum_{j=1}^q \theta_j \cdot \varepsilon(t-j) + \sum_{k=1}^K \beta_k \cdot X_k(t) \quad (3)$$

où :

- $y(t)$ représente la valeur de la consommation à prédire à l'instant t ;
- c est une constante, permettant au modèle de ne pas être nécessairement nul en l'absence de tout autre terme ;
- le terme $\sum_{i=1}^p \phi_i \cdot y(t-i)$ correspond aux valeurs passées de la consommation, jusqu'à p instants en arrière ;
- le terme $\sum_{j=1}^q \theta_j \cdot \varepsilon(t-j)$ correspond aux erreurs de prédiction passées, jusqu'à q instants en arrière ;
- le terme $\beta_k \cdot X_k(t)$ porte les variables exogènes, ici la température ambiante.

Le nom complet du modèle, ARIMAX, signifie *AutoRegressive Integrated Moving Average with eXogenous variables* [1]. Le *I* (*Integrated*) fait référence à un ordre de différenciation d , appliqué à la série lorsque celle-ci n'est pas stationnaire, afin de la rendre stationnaire avant modélisation.

Les hyperparamètres du modèle, les ordres p et q , ainsi que l'ordre de différenciation d , sont déterminés par un *grid search* : cette méthode consiste à tester systématiquement toutes les combinaisons de valeurs possibles parmi un ensemble prédéfini, puis à retenir la combinaison qui minimise une métrique d'erreur donnée. Dans ce travail, le grid search est réalisé sur les ordres $p \in \{0, 1, 2\}$ et $q \in \{0, 1, 2\}$, avec $d = 0$ fixé, la série étant jugée déjà stationnaire.

Puisque $d = 0$, le modèle réalisé est en réalité un **ARMAX** : la partie AR (*AutoRegressive*) correspond aux valeurs passées de la consommation, la partie MA (*Moving Average*) correspond aux erreurs passées, et X correspond à la variable exogène, la température ambiante. L'ordre optimal (p, q) est sélectionné **individuellement pour chaque source**, en retenant celui qui minimise le RMSE sur le jeu de validation ; il n'existe donc pas un ordre unique valable pour l'ensemble des sources du leg.

2.3.3 Implémentation initiale du modèle : prédiction en une seule fois (V0)

La première mise en œuvre du modèle suit le déroulement suivant :

1. **Entraînement et sélection des hyperparamètres.** Pour chaque couple (p, q) testé lors du grid search, le modèle est ajusté sur la période d'apprentissage, puis évalué sur la période de validation. Le couple (p, q) minimisant le RMSE sur la validation est retenu, et les coefficients associés $(\phi_i, \theta_j, \beta_k)$ sont figés à leur valeur estimée.
2. **Prédiction.** Avec ces coefficients désormais figés, le modèle produit ses prédictions sur l'intégralité de la période de test, en une seule fois. Aucune nouvelle observation réelle n'est communiquée au modèle après l'entraînement : chaque prédiction à l'instant t s'appuie donc sur les prédictions précédentes du modèle lui-même plutôt que sur la consommation réellement observée à cet instant.
3. **Évaluation.** Les prédictions obtenues sur l'ensemble de la période de test sont comparées à la consommation réellement observée, et le RMSE correspondant est calculé pour chaque source.

Cette version, notée **V0**, sert de référence pour l'ensemble des versions et modèles présentés dans la suite de ce chapitre.

TABLE 1 – Résultats de la version V0 par source — Leg 30			
SourceId	Ordre (p, q) retenu	RMSE (kW)	RMSE relatif (%)
103	(2,0)	3.43	19.2
116	(2,2)	4.30	38.1
126	(1,1)	4.24	33.2
127	(2,1)	3.99	8.0
128	(1,1)	2.85	3.3
129	(2,1)	5.58	8.8
131	(2,1)	2.99	7.1
132	(0,0)	1.48	17.8
138	(2,2)	5.45	6.0
142	(1,2)	1.43	23.0
146	(1,1)	4.60	23.4
150	(0,2)	0.89	7.5

2.3.4 Résultats et analyse

Le tableau 1 présente, pour chacune des 12 sources du Leg 30, l'ordre (p, q) retenu, le RMSE sur le jeu de test et le RMSE relatif qui en découle.

Ordres retenus. Le grid search retient majoritairement des ordres avec $p \in \{1, 2\}$ et $q \in \{0, 1, 2\}$, confirmant la pertinence d'une composante autorégressive. Deux exceptions : la source 132, ordre $(0, 0)$, réduite à une régression sur la seule température ; et la source 150, ordre $(0, 2)$, sans terme autorégressif.

Deux régimes de performance relative. Le RMSE relatif s'échelonne de 3,3 % (source 128) à 38,1 % (source 116), un facteur supérieur à 11. Un premier groupe (127, 128, 129, 131, 138) obtient les meilleures performances ; un second groupe (103, 116, 126, 132, 142, 146) présente un RMSE relatif nettement plus élevé. Pour comprendre cet écart, trois caractéristiques des sources ont été extraites et comparées entre les deux groupes.

Nombre de reefers connectés. Le Tableau 2 présente, pour chaque source, le nombre de reefers qui lui sont connectés.

TABLE 2 – Nombre de reefers par source, du plus élevé au plus faible											
SourceId	138	128	129	127	131	146	103	142	116	132	126
150											
nb_reefer	30	25	23	17	15	11	10	8	7	6	4
3											

Les sources les plus performantes (128, 131, 138, 129, 127) comptent 15 à 30 reefers ; plusieurs des moins performantes (126, 132, 116) n'en comptent que 4 à 7. Un plus grand nombre de reefers agrégés moyenne les cycles individuels de compresseur, lissant le signal global. La corrélation entre nombre de reefers et RMSE relatif, sur les 12 sources, est de $-0,65$: la tendance est réelle mais n'explique pas tout.

Coefficient de variation de la consommation. Le Tableau 3 présente, pour chaque source, le coefficient de variation de sa consommation sur la période de test.

TABLE 3 – Coefficient de variation (écart-type/moyenne) par source											
SourceId	128	150	138	127	129	131	126	146	103	132	116
142											
CV (%)	7.4	8.3	9.5	10.1	10.5	10.9	12.8	13.0	13.3	13.9	16.6
16.8											

Le classement par coefficient de variation reproduit presque exactement le classement par RMSE relatif : les sources les plus volatiles (142, 116, 132, 103) sont aussi les moins bien prédites, et les plus stables (128, 150) les mieux prédites. La corrélation atteint 0,84, nettement plus forte qu’avec le nombre de reefers. La source 150 confirme cette hypothèse : avec seulement 3 reefers, elle aurait dû mal performer selon le seul critère du nombre de reefers, mais son très faible coefficient de variation (8,3 %) explique son bon RMSE relatif (7,5 %). Le nombre de reefers n’est donc qu’un facteur indirect, statistiquement lié à la volatilité mais pas systématiquement.

La Figure 1 et la Figure 2 illustrent les deux cas les plus stables : dans les deux cas, la courbe prédite reste proche de la consommation réelle. À l’inverse, la Figure 3 et la Figure 4 montrent des sources bien moins bien suivies par le modèle.




FIGURE 1 – Source 150 — seulement 3 reefers, mais consommation très stable (CV = 8,3 %) : bon RMSE relatif (7,5 %) malgré un faible nombre de reefers, confirmant que la volatilité prime sur l’agrégation.




FIGURE 2 – Source 128 — consommation élevée et stable (CV = 7,4 %), RMSE relatif le plus faible (3,3 %).




FIGURE 3 – Source 126 — consommation faible et volatile (CV = 12,8 %), RMSE relatif élevé (33,2 %).




FIGURE 4 – Source 132 — ordre (0,0) : trajectoire lisse pilotée par la seule température, incapable de suivre les oscillations rapides de la consommation réelle.

Asymétrie de la distribution (skewness). Le skewness mesure l’asymétrie d’une distribution : une valeur proche de 0 indique une distribution équilibrée, tandis qu’un skewness négatif marqué indique une fréquence importante de valeurs basses extrêmes par rapport au reste de la distribution, ici, des chutes brutales de consommation, probablement liées à des arrêts de compresseur. La source 116 présente le skewness le plus extrême des 12 sources ($-1,79$), combiné à un coefficient de variation déjà élevé (16,6 %). Cette combinaison explique son RMSE relatif maximal (38,1 %) : le modèle V0, piloté uniquement par la température ambiante, ne peut par construction pas anticiper ces décrochages ponctuels, invisibles dans une variable exogène qui évolue lentement et continûment.

La Figure 5 illustre ce cas extrême : la trajectoire prédite reste lisse alors que la consommation réelle décroche brutalement à plusieurs reprises.




FIGURE 5 – Source 116 — skewness $-1,79$: chutes brutales de consommation non captées par le modèle, RMSE relatif le plus élevé (38,1 %).

Synthèse. Le RMSE relatif de V0 est avant tout piloté par la volatilité intrinsèque de la consommation (coefficient de variation, puis asymétrie), le nombre de reefers n’agissant qu’indirectement. Ce constat confirme la limite structurelle d’ARIMAX : sa formulation linéaire restitue bien la tendance de fond pilotée par la température, mais ne capture pas les irrégularités du signal, quelle qu’en soit l’origine physique.

2.3.5 Étude de l’impact de l’horizon de prédiction (approche multi-horizons)

Motivation. Jusqu’ici, le modèle V0 a été évalué en mode *one-shot* : une seule prédiction, produite pour l’ensemble de la période de test. Or, dans un contexte opérationnel réel, la question posée n’est pas figée : le commandant du navire peut avoir besoin de connaître la consommation attendue dans 2 heures ou dans 24 ou 48 heures. Cette étude vise donc à évaluer la fiabilité de la prédiction V0 selon l’horizon auquel on la sollicite : 2h et 6h (très court terme), 12h et 24h (court terme), et 48h (moyen terme).

Méthode. L’hypothèse théorique est simple : plus l’horizon de prédiction est grand, plus l’erreur commise a l’occasion de se propager et de s’accumuler, et donc plus le RMSE relatif devrait augmenter. Il est important de préciser que cette étude ne constitue pas une nouvelle version du modèle : la trajectoire prédite reste rigoureusement identique à celle de la version V0 déjà présentée, le modèle n’étant entraîné et exécuté qu’une seule fois. Ce qui varie d’un horizon à l’autre est uniquement la portion de cette trajectoire retenue pour le calcul du RMSE, les 2 premières heures pour l’horizon 2h, les 48 premières

heures pour l’horizon 48h. Cette analyse ne vise donc pas à améliorer la prédiction, mais à diagnostiquer à partir de quel horizon celle-ci cesse d’être fiable.

TABLE 4 – RMSE relatif (%) par horizon, pour les 12 sources du Leg 30

SourceId	2h	6h	12h	24h	48h
103	9.7	14.5	15.5	21.9	18.7
116	33.9	34.2	30.4	39.1	43.8
126	27.3	31.6	30.4	43.4	8.1
127	5.4	6.5	6.9	8.4	9.1
128	3.2	3.5	3.1	2.5	4.3
129	7.9	6.5	5.6	7.3	10.6
131	7.1	4.9	5.0	7.2	8.3
132	12.5	12.2	19.9	9.8	24.7
138	4.5	3.1	3.2	7.4	6.4
142	14.8	15.8	16.6	28.1	27.2
146	14.7	17.6	13.7	25.3	23.2
150	6.1	6.2	3.7	6.5	12.4

Confirmation globale de l’attente théorique. Sur 10 des 12 sources, le RMSE relatif à 48h dépasse celui à 2h, confirmant que l’erreur croît globalement avec l’horizon. L’ampleur de cette croissance est cependant très inégale selon les sources, et reproduit fidèlement le clivage déjà établi pour V0 entre les deux groupes de performance. Les sources à faible coefficient de variation (128, 131, 138, 129, 127) voient leur RMSE relatif augmenter de seulement 1 à 4 points de pourcentage entre 2h et 48h (128 : 3,2 % à 4,3 %). À l’inverse, les sources déjà volatiles à V0 (103, 116, 142, 146) voient leur RMSE relatif presque doubler sur la même plage (103 : 9,7 % à 18,7 % ; 142 : 14,8 % à 27,2 %).

Les Figures 6 et 7 illustrent deux sources conformes à la tendance générale, tandis que la Figure 8 montre le cas le plus dégradé.




FIGURE 6 – Source 127 — cas d’école du comportement conforme : croissance quasi monotone du RMSE relatif de 5,4 % (2h) à 9,1 % (48h).




FIGURE 7 – Source 128 — trajectoire prédite quasiment superposée à la réalité sur tous les horizons, RMSE relatif $\leq 4,3$ %.




FIGURE 8 – Source 116 — la consommation réelle oscille violemment (7 à 17 kW) autour d’une prédiction restée quasiment plate; l’écart est déjà marqué dès l’horizon 2h et se creuse à chaque fenêtre supplémentaire, atteignant 43,8 % à 48h.

Cette différence confirme et prolonge l’hypothèse établie pour V0 : la volatilité intrinsèque de la consommation (mesurée par le coefficient de variation) ne se contente pas de dégrader la performance globale du modèle, elle amplifie également sa sensibilité à l’horizon. Sur une source stable comme 128, la trajectoire lissée du modèle reste proche de la réalité quel que soit l’horizon observé ; sur une source volatile comme 116, chaque nouvelle heure de test ajoutée à la fenêtre d’évaluation introduit de nouvelles oscillations que le modèle, piloté uniquement par la température, ne peut par construction pas anticiper.

Un motif secondaire : un creux entre 6h et 12h. Chez plusieurs sources conformes à la tendance générale (103, 129, 131, 142, 146, 150), le RMSE relatif diminue légèrement entre 2h et 6h ou 12h avant de reprendre sa progression. La source 131 l’illustre (7,1 % à 2h, creux à 4,9 % à 6h, puis 8,3 % à 48h) : la fenêtre à 2h, ne comportant qu’un seul point, est plus sensible à un écart ponctuel isolé ; en s’élargissant, l’erreur se moyenne et cette sensibilité s’atténue temporairement.

Incohérences observées : les sources 126 et 132. Deux sources s’écartent nettement de la tendance générale, comme le montrent la Figure 9 et la Figure 10.




FIGURE 9 – Source 126 — le RMSE relatif grimpe à 43,4 % à 24h, puis retombe à 8,1 % à 48h par coïncidence de trajectoire.




FIGURE 10 – Source 132 — évolution erratique du RMSE relatif, cohérente avec l’ordre (0,0) retenu dès V0.

Pour la source 126, la chute à 48h s'explique par le mode de calcul du RMSE par horizon : la fenêtre à 48h contient toujours celle à 24h, plus 24h supplémentaires ; si ces heures supplémentaires correspondent, par coïncidence, à une phase où la consommation réelle redescend vers le niveau déjà atteint par la trajectoire prédite, l'erreur moyennée chute mécaniquement, sans amélioration réelle du modèle. Pour la source 132, l'instabilité sans direction claire s'explique par l'ordre (0, 0) retenu dès V0 : la prédiction ne dépendant que de la température, son erreur à chaque fenêtre dépend uniquement du hasard de la coïncidence avec le niveau de consommation réelle.

Synthèse. Ces deux cas ne remettent pas en cause la tendance générale de dégradation avec l'horizon ; ils révèlent une limite du protocole d'évaluation, sensible aux caractéristiques locales de chaque fenêtre de test. Cela soulève une question naturelle : peut-on corriger la dérive du modèle en lui fournissant les valeurs réelles au fur et à mesure de la prédiction, plutôt qu'en le laissant prédire en une seule fois sur tout l'horizon ? C'est cette idée qui motive la version suivante du modèle, présentée ci-après.

2.3.6 Mise à jour rolling (V2) : principe et analyse du mécanisme

Principe testé. La version V0 présente une limite structurelle : une fois entraînée, elle ne reçoit plus aucune information nouvelle et prédit l'intégralité de l'horizon en une seule fois. L'idée testée dans cette version, notée **V2**, consiste à réactualiser le modèle au fil du temps : à chaque nouveau pas de 2 heures, la vraie valeur de consommation observée est intégrée avant que le modèle ne produise sa prédiction pour le pas suivant, sans réestimer ses coefficients.

TABLE 5 – Ordres retenus et RMSE relatif — V0 vs V2, Leg 30

SourceId	Ordre V0	Ordre V2	RMSE relatif V0 (%)	RMSE relatif V2 (%)
103	(2,0)	(2,2)	19.17	11.46
116	(2,2)	(2,0)	38.06	22.22
126	(1,1)	(2,1)	33.15	19.86
127	(2,1)	(2,2)	7.98	5.02
128	(1,1)	(1,1)	3.29	3.03
129	(2,1)	(2,1)	8.84	4.77
131	(2,1)	(1,2)	7.14	6.52
132	(0,0)	(2,1)	17.81	11.55
138	(2,2)	(1,1)	6.04	3.65
142	(1,2)	(1,2)	23.03	10.63
146	(1,1)	(1,2)	23.45	12.03
150	(2,2)	(1,1)	7.56	7.48

Résultats : une amélioration réelle mais très inégale. La réinjection de la vraie valeur améliore nettement le RMSE relatif sur 9 des 12 sources (103, 116, 126, 127, 129, 132, 138, 142, 146), avec des gains de 35 % à 54 %. Sur les figures correspondantes, la courbe V2 (gris-bleu) suit visiblement mieux la consommation réelle que V0 (rouge) , avec toutefois un léger décalage temporel, discuté plus bas. Trois sources font exception (128, 131, 150), pour lesquelles les courbes V0 et V2 restent quasiment confondues sur toute la période de test.

Les Figures 11, 12 et 13 confirment visuellement l'absence de gain pour ces trois sources : les courbes V0 et V2 restent quasiment confondues.




FIGURE 11 – Source 150 — courbes V0 et V2 quasiment confondues (gain de seulement 1,1 %).




FIGURE 12 – Source 131 — courbes V0 et V2 très proches, gain marginal (7,1 % → 6,5 %).




FIGURE 13 – Source 128 — courbes V0 et V2 quasi superposées.

Problème 1 — pourquoi la mise à jour est-elle sans effet sur 128, 131 et 150 ?
Deux causes distinctes ressortent de l'analyse des coefficients estimés.

Cause 1 : annulation pôle-zéro (131, 150). Un modèle AR/MA perd sa mémoire effective lorsque les racines de ses composantes AR et MA coïncident numériquement. C'est le cas ici. Pour la source 150 (V2), $AR = 0,9998$ et $MA = -0,9999$ produisent des racines quasi identiques :

$$\hat{y}_t = 0,2284 \cdot x_t + 0,9998 \cdot y_{t-1} - 0,9999 \cdot e_{t-1} \quad (4)$$

Pour la source 131 (V2), $AR = 0,99998$ fait face à deux coefficients MA dont la somme vaut exactement 1,0000 :

$$\hat{y}_t = 1,3934 \cdot x_t + 0,99998 \cdot y_{t-1} - 0,8669 \cdot e_{t-1} - 0,1331 \cdot e_{t-2} \quad (5)$$

Dans les deux cas, l'effet AR est presque exactement neutralisé par l'effet MA : le modèle ne dépend plus, en pratique, que de la température exogène x_t , ce qui explique l'absence de gain visible malgré la réinjection.

Cause 2 : effet de plafond, sans annulation (128). Les coefficients sont strictement identiques entre V0 et V2 ($\beta = 1,8772$, $AR = 1,0004$, $MA = -0,8261$), et leurs racines ne coïncident pas. L'absence de gain (7,9 %) s'explique autrement : 128 possède déjà, en V0, le RMSE relatif le plus bas des 12 sources (3,29 %), signe qu'ARIMAX y exploite déjà l'essentiel de ce que sa structure linéaire peut capturer.

Problème 2 — le décalage observé sur les sources qui s’améliorent. Sur les sources où V2 apporte un gain réel, la courbe prédite rattrape la consommation réelle avec un léger retard plutôt que de l’anticiper. Une vérification quantitative écarte l’hypothèse d’une simple recopie de la dernière observation avec décalage fixe.

Les Figures 14 et 15 illustrent ce rattrapage retardé sur les sources où V2 apporte un gain réel.




FIGURE 14 – Source 146 — V2 suit nettement mieux la consommation réelle que V0, avec un décalage visible sur les variations brusques (gain de 48,7 %).




FIGURE 15 – Source 129 — même effet de rattrapage retardé, coefficients strictement identiques entre V0 et V2.

Ce retard s’explique par la persistance modérée du terme autorégressif, une fois l’annulation pôle-zéro écartée. Les sources 129 et 142 sont les cas les plus révélateurs : leurs coefficients sont rigoureusement identiques entre V0 et V2, seul le mécanisme de réinjection change.

$$\text{Source 142 (V0 = V2, ordre (1,2))} \quad \hat{y}_t = 0,3231 \cdot x_t + 0,6716 \cdot y_{t-1} - 0,0978 \cdot e_{t-1} - 0,0969 \cdot e_{t-2} \quad (6)$$

$$\text{Source 129 (V0 = V2, ordre (2,1))} \quad \hat{y}_t = 2,3374 \cdot x_t + 1,2573 \cdot y_{t-1} - 0,2567 \cdot y_{t-2} - 1,0766 \cdot e_{t-1} \quad (7)$$

Pour ces deux sources, les racines AR et MA restent distinctes : le terme autorégressif conserve une capacité de propagation, transmettant une correction sur plusieurs pas avant de s’atténuer, d’où le décalage observé, distinct d’une simple recopie de la valeur précédente.

Synthèse. L’efficacité de la mise à jour rolling dépend d’un équilibre précis entre les racines AR et MA : lorsqu’elles coïncident (131, 150), la mémoire est neutralisée et la réinjection reste sans effet ; près du plafond de performance atteignable (128), le gain reste marginal pour une autre raison ; sur les autres sources, la correction est réelle mais retardée par l’inertie du filtre autorégressif.

2.3.7 Synthèse et limites du modèle ARIMAX

Les trois étapes de ce travail convergent vers un même constat. La performance de V0 dépend avant tout de la volatilité intrinsèque de chaque source : bonne sur les sources stables (128 : 3,3 %), dégradée sur les sources volatiles (116 : 38,1 %). L’étude multi-horizons confirme ce clivage, la trajectoire figée de V0 dérivant sans jamais être recalée.

La mise à jour rolling (V2) corrige cette dérive sur la majorité des sources (gains de 35 % à 54 %), mais son efficacité dépend d’un équilibre précis entre les racines AR et

MA : lorsqu’elles coïncident, la réinjection reste sans effet, et même quand elle opère, la correction reste retardée de plusieurs pas.

Ces limites tiennent à une même cause : ARIMAX repose sur une relation linéaire, alors que la consommation dépend aussi de facteurs contextuels (consigne, position, âge, modèle de l’équipement) que ce formalisme ne peut intégrer sans risquer la même fragilité. C’est ce constat qui motive le passage à un modèle non linéaire, le **XGBoost**, présenté dans la section suivante.

2.4 Modélisation par apprentissage automatique : XGBoost

2.4.1 Définition du modèle

XGBoost (*eXtreme Gradient Boosting*) est un algorithme d’apprentissage supervisé fondé sur le principe du *gradient boosting* : plutôt que d’entraîner un seul modèle complexe, l’algorithme construit une séquence d’arbres de décision simples, chacun étant entraîné pour corriger les erreurs commises par l’ensemble des arbres précédents [2].

La prédiction finale du modèle est obtenue en sommant les contributions de l’ensemble des arbres construits :

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F} \quad (8)$$

où :

- $\hat{y}_i$ représente la valeur prédite pour l’observation i ;
- K est le nombre total d’arbres construits ;
- f_k désigne le k -ième arbre de décision, appartenant à l’espace $\mathcal{F}$ de l’ensemble des arbres possibles ;
- x_i représente le vecteur des variables contextuelles associées à l’observation i .

Les arbres sont construits de manière séquentielle et additive : à chaque étape k , un nouvel arbre f_k est ajouté au modèle pour minimiser une fonction objectif combinant l’erreur de prédiction et un terme de régularisation contrôlant la complexité des arbres [2] :

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (9)$$

où :

- $l(y_i, \hat{y}_i)$ est une fonction de perte mesurant l’écart entre la valeur réelle y_i et la valeur prédite $\hat{y}_i$ (l’erreur quadratique dans le cas d’une régression) ;
- $\Omega(f_k)$ est un terme de régularisation qui pénalise la complexité de l’arbre f_k (nombre de feuilles, profondeur), afin de limiter le sur-apprentissage.

XGBoost est retenu dans ce travail pour sa capacité à capturer des relations **non linéaires** entre la consommation et des variables contextuelles (consigne de température, âge), ce qu’un modèle linéaire comme ARIMAX ne permet pas de représenter, ainsi que pour son efficacité reconnue sur des jeux de données de taille modérée, adaptée au volume de données disponible dans cette étude.

2.4.2 Sélection des hyperparamètres

Contrairement à ARIMAX, qui ajuste un modèle séparé pour chaque source, XGBoost est ici entraîné de façon poolée : un seul modèle apprend sur les données de toutes les sources combinées.

Trois hyperparamètres sont sélectionnés par grid search : `learning_rate` (taux d'apprentissage), `max_depth` (profondeur maximale des arbres) et `n_estimators` (nombre d'arbres). Le Tableau 6 présente les valeurs testées pour chacun.

TABLE 6 – Grille d'hyperparamètres testée — XGBoost

Hyperparamètre	Valeurs testées
<code>learning_rate</code>	0,01 ; 0,05 ; 0,1 ; 0,3
<code>max_depth</code>	3 ; 4 ; 6
<code>n_estimators</code>	50 ; 100 ; 200

Ces plages s'appuient sur les recommandations de la documentation officielle de XGBoost [3]. Pour `learning_rate`, une valeur basse (0,01) ralentit l'apprentissage mais le stabilise, tandis qu'une valeur haute (0,3, valeur par défaut) accélère la convergence au risque d'un sur-apprentissage plus rapide. Pour `max_depth`, une profondeur plus élevée augmente le risque de sur-apprentissage en autorisant chaque arbre à mémoriser des interactions trop spécifiques aux données d'entraînement ; la valeur par défaut (6) est incluse comme borne supérieure, avec deux valeurs plus conservatrices (3 et 4). Pour `n_estimators`, un nombre d'arbres trop élevé combiné à un `learning_rate` élevé favorise le sur-apprentissage, tandis qu'un nombre trop faible peut empêcher la convergence ; l'arrêt anticipé (*early stopping*) limite cette dépendance en stoppant l'entraînement dès que le RMSE de validation cesse de s'améliorer.

Chaque combinaison est entraînée sur le jeu d'apprentissage et évaluée sur le jeu de validation ; celle qui minimise ce RMSE est retenue, puis appliquée pour produire les prédictions sur le jeu de test.

2.4.3 Comparaison ARIMAX vs XGBoost – Système dynamique autorégressif

Méthodologie Afin de comparer ARIMAX et XGBoost de façon équitable, un protocole à mémoire équivalente a été mis en place, le même périmètre que celui utilisé par ARIMAX, qui ne peut modéliser qu'une série temporelle à la fois.

ARIMAX intègre nativement une composante autorégressive $AR(p)$ exploitant les valeurs passées de la consommation. Pour donner à XGBoost une capacité de mémoire comparable, trois jeux de features ont été construits, reproduisant les ordres $p = 0$, $p = 1$ et $p = 2$ testés par ARIMAX :

- $p = 0$: température ambiante ;
- $p = 1$: température ambiante + consommation au pas précédent, $t - 1$;
- $p = 2$: température ambiante + consommation à $t - 2$.

Pour chaque source, un modèle XGBoost distinct est entraîné pour chacun des trois ordres, avec sa propre recherche d'hyperparamètres (*grid search* sur `learning_rate`, `max_depth`, `n_estimators`, sélectionnée sur validation). L'ordre p optimal pour chaque source est ensuite choisi sur le RMSE de **validation** reproduisant exactement le protocole de sélection d'ordre (p, d, q) utilisé pour ARIMAX, où le test ne sert jamais à la

sélection afin d'éviter tout biais optimiste. Le RMSE de test rapporté est celui du p ainsi sélectionné.

Résultats Hyperparamètres retenus par ordre

Le Tableau 7 présente les hyperparamètres retenus par grid search pour chaque ordre p .

TABLE 7 – Hyperparamètres retenus par ordre p (Leg 30)

Ordre p	<i>learning_rate</i>	<i>max_depth</i>	<i>n_estimators</i>	RMSE val.
0	0.3	3	50	32.059
1	0.3	6	50	2.493
2	0.1	3	50	2.534

L'ordre $p = 0$ présente un RMSE de validation nettement dégradé (32.06, contre 2.49 et 2.53 pour $p = 1$ et $p = 2$) : sans mémoire de consommation , le modèle poolé ne dispose d'aucune variable suffisamment informative pour différencier les sources entre elles. Cet ordre n'est en conséquence jamais retenu comme optimal pour aucune source (cf. tableau 8).

Comparaison par source

Le Tableau 8 détaille, pour chaque source, l'ordre ARIMAX, l'ordre p optimal retenu pour XGBoost et le gain obtenu.

TABLE 8 – Comparaison ARIMAX vs XGBoost (ordre p optimal, sélectionné sur validation), Leg 30

SourceId	Ordre ARIMAX	RMSE rel. ARIMAX	p choisi	RMSE rel. XGBoost	Gain XGBoost (%)
103	(2, 0)	19.2%	1	7.6%	+60.4
116	(2, 2)	38.1%	1	22.9%	+39.8
126	(1, 1)	33.2%	2	15.5%	+53.3
127	(2, 1)	8.0%	2	3.9%	+51.6
128	(1, 1)	3.3%	1	8.0%	-142.5
129	(2, 1)	8.8%	1	8.6%	+2.7
131	(2, 1)	7.1%	2	8.3%	-16.8
132	(0, 0)	17.8%	2	13.6%	+23.6
138	(2, 2)	6.0%	1	6.5%	-8.3
142	(1, 2)	23.0%	1	20.6%	+10.4
146	(1, 1)	23.4%	1	12.0%	+48.9
150	(2, 2)	7.5%	1	9.5%	-26.3
Moyenne	–	16.3%	–	11.4%	–

Analyse

XGBoost surpasse ARIMAX sur 8 des 12 sources, avec un RMSE relatif moyen de 11.4 % contre 16.3 % pour ARIMAX, soit un gain global de l'ordre de 30%. Ce résultat confirme que, à information égale, XGBoost constitue une alternative crédible à ARIMAX pour cette tâche.

Répartition de l'ordre optimal : l'ordre $p = 1$ est retenu pour 8 sources sur 12, $p = 2$ pour les 4 restantes, et $p = 0$ n'est jamais sélectionné, confirmant qu'une mémoire d'au moins un pas de temps est systématiquement nécessaire pour obtenir une performance satisfaisante.

Les Figures 16 et 17 illustrent deux cas de gain net pour XGBoost.




FIGURE 16 – SourceId 103 (Leg 30, $p = 1$) – cas de gain net pour XGBoost (+60.4 %)




FIGURE 17 – SourceId 146 (Leg 30, $p = 1$) – bon suivi de la dynamique par XGBoost (+48.9 %)

Quatre sources font exception (128, 131, 138, 150), où ARIMAX reste supérieur. Ces cas partagent une caractéristique commune : un RMSE relatif ARIMAX déjà très faible (entre 3.3 % et 7.5 %), signe d'une dynamique de consommation lisse et régulière qu'ARIMAX, de par sa structure statistique continue, capture nativement mieux qu'un modèle d'arbres de décision comme XGBoost, plus adapté aux dynamiques discontinues ou irrégulières. La source 128 illustre le cas le plus marqué (gain de -142.5%), où le RMSE XGBoost est resté élevé malgré la mémoire ajoutée.

Les Figures 18 et 19 montrent à l'inverse deux cas limites où ARIMAX reste supérieur.




FIGURE 18 – SourceId 128 (Leg 30, $p = 1$) – cas limite où ARIMAX reste supérieur (-142.5%)




FIGURE 19 – SourceId 131 (Leg 30, $p = 2$) – cas limite où ARIMAX reste supérieur (-16.8%)

2.4.4 Enrichissement du modèle XGBoost par des features contextuelles

Introduction Cette partie explore dans quelle mesure XGBoost peut être amélioré en exploitant des leviers propres à sa nature de modèle multi-sources, à savoir des features contextuelles supplémentaires décrivant les reefers connectés à chaque source, notamment la température de consigne et l'âge des reefers. Dans le but de prédire la consommation du Leg 30, l'entraînement est réalisé sur un périmètre poolé de 7 legs (21, 22, 23, 24, 30, 34, 44) en raison de la variabilité insuffisante obtenue avec un périmètre restreint à un unique voyage. Cette section constitue une recherche de la meilleure configuration opérationnelle atteignable avec XGBoost.

Construction des features contextuelles Les variables contextuelles disponibles décrivent les reefers connectés à chaque source (consigne de température, âge), au niveau individuel. Or, la consommation est mesurée au niveau agrégé de la source, qui regroupe plusieurs reefers pouvant appartenir à des catégories différentes. Le principe retenu pour construire les features est donc, pour chaque catégorie, de transformer la répartition des reefers d’une source en une **fraction pondérée** de reefers appartenant à chaque classe, à chaque instant t :

$$f_{k,s,t} = \frac{N_{k,s,t}}{\sum_{\ell=1}^K N_{\ell,s,t}} \quad (10)$$

où $N_{k,s,t}$ est le nombre de reefers de la source s appartenant à la catégorie k à l’instant t , et K le nombre total de catégories considérées. Cette fraction permet de résumer, pour chaque catégorie qualitative, la composition de la source sans dépendre de son nombre total de reefers.

Consigne de température (setpoint). Les reefers sont répartis en cinq classes de consigne de température : *deep_frozen*, *frozen*, *chilled*, *fresh* et *ambient*. À chaque instant, la composition de la source selon ces classes est résumée par les cinq fractions $f_{k,s,t}$ correspondantes. Deux indicateurs synthétiques en sont ensuite dérivés :

$$z_{\text{thermal},s,t} = \sum_{k=1}^K f_{k,s,t} \cdot \max(0, T_{\text{amb},t} - T_{\text{set},k}) \quad (11)$$

le *thermal lift*, qui pondère l’écart entre la température ambiante et la température de consigne représentative de chaque classe par la fraction de reefers concernée, donnant ainsi une mesure globale de l’effort de réfrigération théoriquement requis par la source, et

$$z_{\text{set-het},s,t} = -\frac{\sum_{k=1}^K f_{k,s,t} \log f_{k,s,t}}{\log K} \quad (12)$$

l’*hétérogénéité de consigne*, une entropie normalisée qui vaut 0 lorsque tous les reefers de la source partagent la même consigne, et se rapproche de 1 lorsque les reefers sont répartis de façon égale entre les différentes classes.

Âge de l’équipement. L’âge de l’équipement de réfrigération, lorsqu’il est manquant, est imputé par une valeur fixe observée sur l’ensemble du jeu de données ; deux stratégies ont été testées à cet effet, l’une imputant par la valeur minimale observée, l’autre par la valeur maximale. Les reefers sont ensuite répartis en quatre classes d’âge : *young* (moins de 5 ans), *moderate* (5 à 10 ans), *old* (10 à 15 ans) et *very_old* (15 ans et plus). Pour chaque source, l’âge moyen et sa dispersion sont calculés :

$$z_{\text{mean-age},s,t} = \frac{1}{N_{s,t}} \sum_{j=1}^{N_{s,t}} \text{Age}_{j,t}, \quad z_{\text{age-disp},s,t} = \sqrt{\frac{1}{N_{s,t}} \sum_{j=1}^{N_{s,t}} (\text{Age}_{j,t} - z_{\text{mean-age},s,t})^2} \quad (13)$$

auxquels s’ajoutent les fractions $f_{k,s,t}$ de reefers par classe d’âge et l’hétérogénéité correspondante.

Méthodologie de test La démarche adoptée consiste à tester d’abord la température seule associée à l’historique de consommation, comparée directement à ARIMAX dans un protocole à mémoire équivalente, puis à ajouter progressivement chaque groupe de features contextuelles (consigne de température, âge des équipements) afin d’évaluer isolément l’apport de chacun sur la qualité de la prédiction. Pour chaque configuration, la fenêtre temporelle des statistiques glissantes de consommation (testée sur des durées de 4h, 6h, 8h, 10h et 12h) ainsi que les hyperparamètres du modèle sont sélectionnés automatiquement par recherche sur grille, en minimisant le RMSE de validation ; le test ne sert jamais à cette sélection. La performance est mesurée par le RMSE relatif, rapport entre le RMSE de test et la moyenne de la consommation réelle observée sur cette même période, ce qui permet de comparer directement chaque configuration à la vérité terrain.

Configuration initiale : température et historique de consommation La configuration de départ associe la température ambiante instantanée aux statistiques glissantes de consommation passée (moyenne, minimum, maximum, écart type, ainsi que la valeur au pas précédent). Cette configuration atteint un RMSE relatif moyen de 8.8 % en entraînement poolé sur les 7 legs.

La fenêtre retenue est de 12h, avec les hyperparamètres $learning_rate = 0.05$, $max_depth = 4$ et $n_estimators = 200$. Le Tableau 9 détaille le RMSE relatif obtenu par source pour cette configuration.

TABLE 9 – RMSE relatif : température et historique de consommation (entraînement 7 legs)

SourceId	RMSE relatif
103	7.6%
116	25.8%
126	16.0%
127	3.6%
128	3.6%
129	4.3%
131	5.8%
132	9.0%
138	3.3%
142	8.7%
146	11.5%
150	5.9%
Moyenne	8.8%




FIGURE 20 – SourceId 128, entraînement poolé sur 7 legs




FIGURE 21 – SourceId 116, entraînement poolé sur 7 legs

On remarque que l’ajout des lags de consommation permet un suivi particulier des variations brusques de la consommation réelle, en entraînement poolé sur les 7 legs. Cependant le RMSE relatif reste hétérogène selon les sources : inférieur à 4 % pour 127, 128 ou 138 (figure 20), il atteint 25.8 % pour la source 116 (figure 21) et 16.0 % pour 126. Pour ces sources, la température et l’historique de consommation ne suffisent pas à expliquer la dynamique, ce qui motive l’ajout de features décrivant la composition des reefers, en commençant par la consigne de température.

Ajout des features de consigne de température La première feature contextuelle testée décrit la répartition des reefers d’une source selon leur consigne de température (setpoint), résumée par les fractions de reefers appartenant à chacune des cinq classes ainsi que par les indicateurs de charge thermique et d’hétérogénéité présentés précédemment. Le Tableau 10 présente le RMSE relatif obtenu et le gain associé pour chaque source.

TABLE 10 – RMSE relatif et gain : ajout du setpoint (entraînement 7 legs)

SourceId	RMSE relatif (+ Setpoint)	Gain
103	7.5%	1.5%
116	21.4%	17.0%
126	15.2%	5.3%
127	3.4%	6.1%
128	3.7%	-4.2%
129	4.1%	3.1%
131	5.9%	-1.4%
132	10.0%	-11.2%
138	3.3%	-0.8%
142	8.5%	1.6%
146	11.7%	-1.9%
150	5.9%	-0.0%
Moyenne	8.4%	

L’ajout du setpoint améliore le RMSE relatif moyen (8.8 % à 8.4 %) , mais ce gain n’est pas uniforme entre les sources. La source 116 illustre le cas le plus favorable, avec une réduction du RMSE relatif de 25.8 % à 21.4 % ce qui suggère que la consommation de cette source dépend fortement de la composition de ses reefers en termes de consigne de température.

À l'inverse, la source 132 se dégrade légèrement (de 9.0 % à 10.1 %), ce qui indique que l'ajout de ces sept features supplémentaires n'apporte pas d'information utile pour cette source et introduit à la place un léger bruit. La Figure 22 montre l'amélioration obtenue sur la source 116, tandis que la Figure 23 illustre la dégradation observée sur la source 132.




FIGURE 22 – SourceId 116 (entraînement 7 legs) : amélioration du suivi grâce au setpoint




FIGURE 23 – SourceId 132 (entraînement 7 legs) : cas où l'ajout du setpoint dégrade légèrement le suivi

Le setpoint n'expliquant qu'une partie de l'écart de performance entre sources, une autre hypothèse est testée : l'âge des équipements, susceptible d'influencer la consommation via une efficacité thermique dégradée pour les reefers les plus anciens.

Ajout des features d'âge des équipements La seconde feature testée décrit l'âge des reefers connectés à chaque source (âge moyen, dispersion, fractions par classe d'âge et hétérogénéité correspondante), avec une imputation des valeurs manquantes par la valeur maximale observée, retenue après comparaison avec une imputation par la valeur minimale, cette dernière s'étant montrée nettement moins robuste sur certaines sources. Le Tableau 11 présente les résultats obtenus.

TABLE 11 – RMSE relatif et gain : ajout de l'âge (entraînement 7 legs)

SourceId	RMSE relatif (+ Âge)	Gain
103	7.5%	1.1%
116	20.6%	20.1%
126	15.2%	5.1%
127	4.0%	-11.1%
128	3.7%	-2.4%
129	4.4%	-2.1%
131	5.8%	0.1%
132	10.0%	-11.1%
138	3.7%	-12.3%
142	8.4%	3.7%
146	11.9%	-3.5%
150	5.7%	2.8%
Moyenne	8.4%	

Les résultats obtenus avec l'âge suivent un schéma très proche de ceux du setpoint, avec un gain moyen identique (8.4 % contre 8.4 % pour le setpoint). La source 116 bénéficie

à nouveau de l'ajout de cette feature, avec une amélioration du RMSE relatif de 25.8 % à 20.6 %, confirmant que cette source est particulièrement sensible à la composition de ses reefers plutôt qu'à la seule température ambiante.

La source 132 se dégrade également avec l'âge (de 9.0 % à 10.0 %), ce qui confirme que cette source résiste systématiquement à l'ajout de features contextuelles supplémentaires, quelle que soit leur nature. La Figure 24 et la Figure 25 mettent ces deux comportements en évidence.




FIGURE 24 – SourceId 116 (entraînement 7 legs) : amélioration du suivi grâce à l'âge des reefers




FIGURE 25 – SourceId 132 (entraînement 7 legs) : cas où l'ajout de l'âge dégrade le suivi

2.4.5 Bilan de l'enrichissement

Les trois versions testées donnent un RMSE relatif moyen quasi identique par rapport à la consommation réelle : 8.09 % pour temp + conso_lags, 7.77 % avec le setpoint, 7.90 % avec l'âge. Cet écart est trop faible pour retenir une version particulière comme supérieure aux autres.

Ce résultat indique que l'essentiel de la capacité prédictive de XGBoost provient de l'historique de consommation (conso_lags), les features de setpoint et d'âge n'apportant qu'un raffinement marginal et inconstant selon les sources. Dans les trois cas, les prédictions restent proches de la consommation réelle mais un écart persiste pour certaines sources, ce qui traduit une limite structurelle du modèle plutôt qu'un manque d'information contextuelle : connaître la consigne de température ou l'âge des reefers ne suffit pas à combler ce décalage.

2.5 Synthèse comparative et valeur ajoutée

Le Tableau 12 synthétise les principes, points forts, limites et performances des deux approches.

TABLE 12 – Synthèse comparative ARIMAX vs XGBoost

	ARIMAX	XGBoost
Principe	Modèle statistique linéaire, un modèle par source	Arbres de décision, entraînement poolé multi-sources et multi-legs
Mémoire	Native (AR/MA)	Reconstruite via des lags de consommation
Points forts	Interprétable, performant sur sources stables, peu gourmand en données	Performant sur sources volatiles, exploite le pooling et les variables contextuelles
Limites	Dérive en mode one-shot, une seule variable exogène	Sensible au sur-apprentissage sur certaines features
RMSE relatif (Leg 30)	16.3 %	11.4 % (mémoire équivalente), 7.8–7.9 % (configurations enrichies, 7 legs)

La comparaison à mémoire équivalente établit que XGBoost surpasse ARIMAX d'environ 30 % sur le RMSE relatif moyen, à information égale. L'exploitation des capacités propres à XGBoost (features contextuelles, pooling sur 7 legs) permet d'aller au-delà, avec un RMSE relatif ramené à 7.8–7.9 %, plus de deux fois inférieur à celui d'ARIMAX.

Cette double démarche apporte une réponse argumentée au problème posé : elle distingue le gain méthodologique intrinsèque à XGBoost du gain opérationnel obtenu grâce aux données supplémentaires, offrant une base de choix entre un modèle simple et interprétable (ARIMAX, adapté à un leg isolé) et une configuration XGBoost poolée, plus performante mais plus gourmande en données.

2.6 État final et perspectives

Ce stage a permis de mettre en place un protocole rigoureux de comparaison de modèles de prédiction, garantissant par un découpage apprentissage/validation/test que la sélection des hyperparamètres ne biaise jamais l'évaluation finale. Il établit qu'ARIMAX offre une référence fiable sur les sources stables, que sa version rolling en corrige partiellement la dérive, et que XGBoost, enrichi et poolé, dépasse significativement cette référence.

Plusieurs limites doivent être soulignées. Le volume de données reste modeste (7 legs exploitables sur une quarantaine disponibles), limitant la capacité de généralisation. Certaines sources, telle la source 127, se sont montrées instables face à certaines features contextuelles testées mais non retenues dans la configuration finale (notamment le poids), ce qui suggère une possible anomalie de données non investiguée faute de temps.

Plusieurs pistes se dégagent pour la suite du projet TNTM. L'extension du pooling à l'ensemble des legs disponibles permettrait de tester la robustesse de la configuration retenue. Une prédiction multi-horizons avec XGBoost, comparable à celle menée pour ARIMAX, évaluerait enfin sa stabilité au-delà d'un seul pas de temps.

3 Les compétences centraliennes et l'utilisation de l'intelligence artificielle

3.1 Les compétences centraliennes

C4-1 : Se connaître, se construire

Questionner ses modes de fonctionnement préférentiels

Je travaille aussi bien seule qu'en équipe, sans réelle préférence entre les deux : le travail individuel me permet de me concentrer pleinement et sérieusement sur une tâche, tandis que le travail en équipe apporte une réelle valeur ajoutée à travers le partage et la confrontation des idées. Ce que je recherche dans le travail collectif, c'est une communication ouverte, où une idée est discutée et remise en question plutôt qu'appliquée telle quelle.

Ce mode de fonctionnement s'est retrouvé pendant le stage : je travaillais en autonomie au quotidien, tout en échangeant presque chaque jour avec ma tutrice lors de courtes réunions pour cadrer mon travail, poser mes questions et discuter des résultats. Une réunion d'équipe hebdomadaire venait compléter ce rythme, où je présentais mon avancement et recevais des retours constructifs. Face à un retour contradictoire ou une critique, j'ai pris l'habitude d'abord de tenter d'y répondre avec mes propres connaissances, puis d'accueillir avec un esprit ouvert les remarques de personnes plus expérimentées que moi, que ce soit sur le fond ou sur la manière de présenter mon travail, en veillant ensuite à ne pas reproduire les mêmes erreurs.

Affiner sa connaissance de soi et des autres

Ce stage m'a permis de prendre conscience d'une limite dans ma façon de travailler : ma forte concentration sur les tâches à accomplir, en particulier lorsque je rencontre une difficulté que je cherche à résoudre par moi-même avant de solliciter de l'aide, m'a quelque peu isolée du reste de l'environnement de travail. J'ai ainsi peu pris le temps, en dehors des interactions avec mes camarades de promotion présents dans le même laboratoire, d'aller à la rencontre des autres stagiaires et doctorants pendant la journée. . Ce constat me permet d'identifier un axe de progression pour mes prochaines expériences professionnelles : mieux équilibrer concentration sur le travail et ouverture vers les personnes qui m'entourent.

Formuler des hypothèses sur ses orientations professionnelles en lien avec ses valeurs

Ce stage confirme mon projet professionnel de travailler dans le domaine de l'intelligence artificielle et de la donnée : j'y ai découvert et pratiqué des méthodes de machine learning appliquées à un problème concret de prédiction, un domaine sur lequel je n'avais pas encore travaillé, et cette découverte a été une source de satisfaction.

En revanche, cette expérience en laboratoire de recherche, après un premier stage en entreprise au Maroc, m'a permis de clarifier mon orientation : je souhaite poursuivre ma carrière en entreprise plutôt qu'en recherche académique. Les échanges avec ma tutrice et M. Graton m'ont confirmé que la recherche exige une motivation et un attachement profonds à la recherche que je ne ressens pas suffisamment pour en faire mon métier. J'ai en revanche beaucoup apprécié l'environnement de travail du laboratoire : une ambiance chaleureuse et solidaire entre tout le monde, un mode de fonctionnement que je souhaite retrouver dans mes futures expériences en entreprise. Des valeurs comme l'autonomie, la rigueur et la volonté constante de m'améliorer ont par ailleurs été pleinement confirmées au cours de ce stage, notamment à travers les nombreux essais et itérations menés avant

d'aboutir aux résultats présentés dans ce rapport.

C4-3 : Conduire des transformations dans son organisation

Tout au long du stage, j'ai été amenée à remettre en question et à faire évoluer plusieurs choix méthodologiques établis dans le projet TNTM, contribuant ainsi à l'amélioration progressive des pratiques de l'équipe.

J'ai par exemple proposé d'enrichir les modèles avec de nouvelles variables exogènes au-delà de la seule température ambiante, en testant notamment l'ajout de la vitesse du vent. Après analyse des résultats, cette variable n'apportait qu'un gain marginal et insuffisant pour justifier la complexité supplémentaire qu'elle introduisait ; j'ai donc pris la décision, argumentée auprès de ma tutrice, de ne pas la retenir dans la configuration finale. Cette démarche illustre ma capacité à proposer des pistes d'amélioration, à les tester rigoureusement, puis à assumer et communiquer une décision de ne pas les valider lorsque les résultats ne le justifient pas, plutôt que de conserver une complexité inutile par simple inertie.

Dans la même logique, j'ai identifié et corrigé un argument méthodologique invalide qui avait été utilisé pour justifier la normalisation des variables entre sources. J'ai également remis en question la pertinence d'une variable pourtant intuitive, le nombre de reefers connectés à une source, que j'ai écartée de la configuration finale après avoir démontré, données à l'appui, qu'elle n'apportait pas d'amélioration significative une fois les variables de consommation passée incluses. Ces remises en question, bien qu'à l'échelle d'un projet de recherche plutôt que d'une organisation entière, m'ont permis d'identifier des leviers d'amélioration concrets et de les faire accepter par mon équipe grâce à une argumentation rigoureuse appuyée sur des résultats.

C5-1 : Anticiper et s'engager

J'ai choisi ce stage en laboratoire de recherche avec la volonté d'explorer ce milieu, différent de l'entreprise, et d'en comprendre le fonctionnement ainsi que le parcours d'un chercheur ou d'un doctorant. J'ai spécifiquement choisi le laboratoire LIS car il proposait des sujets en lien direct avec mon projet professionnel dans le domaine de l'intelligence artificielle et de la donnée, parmi plusieurs sujets proposés par M. Graton.

Ce choix s'inscrit dans la continuité de mon parcours : une formation d'ingénieure en informatique au Maroc, suivie d'un double diplôme à Centrale Méditerranée où j'ai orienté mes électifs vers l'informatique et choisi de suivre le parcours SISN, puis choisi l'option Intelligence Artificielle et Apprentissage Machine en troisième année. Ce stage est donc cohérent avec mes choix professionnels passés et avec le système de valeurs qui les sous-tend : la volonté de me spécialiser progressivement dans le domaine de l'IA appliquée.

C5-2 : Donner du sens

Mon sujet de stage s'inscrit dans un enjeu de soutenabilité : celui de la sobriété énergétique du transport maritime réfrigéré. Les conteneurs reefer consomment une énergie importante pour maintenir une température constante durant des traversées de plusieurs semaines, et mieux comprendre et prédire cette consommation constitue un préalable nécessaire à toute stratégie d'optimisation énergétique à l'échelle d'une flotte.

En comparant deux familles de modèles, les modèles statistiques de séries temporelles (ARMAX) et les modèles d'apprentissage automatique (XGBoost), mon travail vise à

identifier l'approche la plus fiable pour anticiper cette consommation, ce qui pourrait à terme permettre une meilleure allocation des ressources énergétiques et une détection plus rapide des comportements de consommation anormaux.

3.2 L'utilisation de l'intelligence artificielle dans le cadre de ce stage

J'ai utilisé l'intelligence artificielle de façon ponctuelle et ciblée pendant ce stage, principalement comme outil d'appui à ma compréhension et à mon efficacité, sans qu'elle ne se substitue à mon travail de conception. Je l'ai sollicitée pour rechercher des sources et comprendre des définitions ou des algorithmes que je ne maîtrisais pas encore, ce qui m'a permis de gagner du temps dans mes phases de montée en compétence. Je l'ai également utilisée pour m'aider à comprendre certains extraits de code existants, ainsi que pour traduire en code des algorithmes que je concevais moi-même en pseudo-code : je définissais la logique et la structure de l'algorithme, et l'IA m'assistait dans son implémentation technique, ce qui accélérail l'écriture tout en me laissant la responsabilité entière de la conception et de la validation des résultats.

Conclusion

Ce stage a permis de répondre à l'objectif fixé initialement par le laboratoire et CMA CGM : proposer et comparer différentes approches de modélisation de la consommation électrique des reefers, à partir des données réelles du Leg 30. Deux familles de modèles ont été mises en œuvre et évaluées selon un protocole rigoureux d'entraînement, de validation et de test, garantissant une comparaison non biaisée.

Le modèle ARIMAX a permis d'établir une référence de performance interprétable, dont l'analyse a révélé que la qualité de prédiction dépend avant tout de la volatilité intrinsèque de chaque source, et que sa principale limite, la dérive en prédiction one-shot, peut être partiellement corrigée par une réactualisation régulière du modèle. Le modèle XGBoost, à mémoire équivalente, a surpassé ARIMAX d'environ 30 % sur le RMSE relatif moyen, confirmant l'apport d'une modélisation non linéaire et poolée sur plusieurs sources. Son enrichissement par des variables contextuelles et son entraînement sur un périmètre élargi à 7 legs ont permis d'atteindre un RMSE relatif de l'ordre de 7,8 à 7,9 %, la principale source de gain restant toutefois l'historique de consommation plutôt que les variables contextuelles testées, dont l'apport s'est révélé marginal et inconstant selon les sources.

Au-delà du volet technique, ce stage a été une première expérience en laboratoire de recherche, qui m'a permis de développer mes compétences en science des données et en modélisation. Il confirme mon souhait de construire ma carrière dans l'intelligence artificielle et le machine learning, un domaine dans lequel j'ai pu, à travers ce projet, pratiquer concrètement les méthodes qui m'intéressent.

Les résultats obtenus ouvrent plusieurs perspectives pour la suite du projet TNTM, notamment l'extension du pooling à l'ensemble des legs disponibles et l'évaluation de la stabilité de XGBoost sur plusieurs horizons de prédiction, dans la continuité de l'étude déjà menée pour ARIMAX. Ils constituent une base solide pour la suite du projet, et pourraient à terme contribuer à une meilleure anticipation des besoins énergétiques de la flotte de CMA CGM.

Bibliographie

Références

- [1] GeeksforGeeks, *What Is an ARIMAX Model ?*, <https://www.geeksforgeeks.org/artificial-intelligence/what-is-an-arimax-model/>
- [2] XGBoost Documentation, *Introduction to Boosted Trees*, <https://xgboost.readthedocs.io/en/stable/tutorials/model.html>
- [3] XGBoost Documentation, *XGBoost Parameters*, <https://xgboost.readthedocs.io/en/stable/parameter.html>
- [4] M. Boulakebch, S. Sellami, G. Graton, *A Context-Aware Framework for Time Series Forecasting of Energy Consumption : A Maritime Case Study*, ACIIDS 2026.
- [5] *Physics-Guided Data-Driven AI Framework for Energy Consumption Forecasting*, Energy and AI (soumis).